

THU THẬP DỮ LIỆU ĐA NGUỒN

1. Mục tiêu

Mục tiêu của bài lab này là yêu cầu sinh viên thực hiện thu thập (crawl/scrape) dữ liệu từ nhiều nguồn khác nhau trên Internet, bao gồm mạng xã hội, các nền tảng video – thảo luận và báo chí. Sinh viên cần làm quen với việc xử lý dữ liệu không đồng nhất, đến từ nhiều loại nền tảng khác nhau. Các nội dung dữ liệu thu thập có thể liên quan đến các chủ đề về chiến sự gần nhất, liên quan đến kinh tế, liên quan đến các show âm nhạc, ...

2. Các nhánh dữ liệu cần thu thập ([Link hướng dẫn crawl Youtube và TikTok](#))

2.1. Mạng xã hội

Thu thập bình luận từ: (có thể bổ sung chỉnh sửa từ link code cung cấp để hoàn thiện hơn)

- Facebook
- TikTok

Dữ liệu cần:

- Nội dung comment, phản hồi của comment đó.
- Thời gian
- ID bài viết hoặc video
- Nội dung của bài viết

2.2. Nền tảng video và thảo luận

Thu thập dữ liệu từ: (có thể bổ sung chỉnh sửa từ link code cung cấp để hoàn thiện hơn)

- YouTube
- Reddit
- Twitter

Dữ liệu cần:

- Nội dung comment hoặc bài viết
- Thời gian
- Metadata (likes, replies nếu có)

2.3. Báo chí (Thực hiện bổ sung code thêm – bài tập chưa có code hướng dẫn)

Thu thập dữ liệu từ các nguồn (Về các chiến sự gần đây của Iran, Mỹ, Isreal):

- CNN
- BBC
- The New York Times
- VnExpress

Dữ liệu cần:

- Tiêu đề bài báo
- Nội dung bài báo
- Thời gian đăng
- Comment

3. Yêu cầu về thời gian dữ liệu

- Dữ liệu phải được thu thập trong cùng một khoảng thời gian xác định
- Ví dụ: trong vòng 1–2 tháng gần nhất
- Cần ghi rõ khoảng thời gian đã chọn trong báo cáo

4. Yêu cầu kỹ thuật

4.1. Công cụ

Sinh viên có thể sử dụng:

- Python
- Các thư viện: requests, BeautifulSoup, Selenium
- API chính thức

4.2. Yêu cầu code

- Viết code thu thập dữ liệu cho từng nguồn
- Code phải:
 - Có chú thích rõ ràng
 - Có xử lý lỗi cơ bản
 - Có lưu dữ liệu
- Định dạng lưu: File CSV hoặc JSON

5. File hướng dẫn (Documentation)

Sinh viên nộp 1 file mô tả gồm:

1. Giới thiệu các nguồn dữ liệu đã chọn
2. Mô tả cách thu thập dữ liệu cho từng nguồn
3. Công cụ và thư viện sử dụng

6. Video demo

Yêu cầu:

- Thời lượng: 5–10 phút
- Có thuyết minh bằng giọng nói

Nội dung:

1. Giới thiệu ngắn gọn
2. Demo chạy code
3. Trình bày dữ liệu thu thập được

7. Nộp bài

Sinh viên nộp:

- Source code (File colab)
- Video demo
- Dataset thu thập được

Đặt các tên file theo quy tắc: MSSV_BTTH1 ở các file nộp bài. Nếu nội dung quá lớn các em nộp một file pdf chứa đường link lưu tới các file nộp được yêu cầu (File cần chứa thông tin sinh viên và đường link). Cần share quyền để giảng viên có thể dễ dàng vào xem và chấm điểm.